

8-7-2026

التاريخ:

الموضوع:

AI vs ML

AI: Matching or exceeding the intelligence of all capabilities of a human such as (discover, infer, Reason).

ML: involves predictions or decisions based on data and statistical analysis for data.

- the more we feed the system, the more accurate predictions ("learn")

ML has 2 types: (supervised learning) (unsupervised)

1] **Supervised learning**:
a training method where models are trained using **labeled datasets**, requiring human to determine the features that distinguish the data.

2] **Unsupervised learning**:

A training method where algorithms discover hidden patterns and cluster data groupings from unlabeled raw data on their own.

* **ML is a subset from AI (ML CAI)**

في ال ML توجيه ال Feature يحتاج دايمًا للإنسان يعني أنا اللي بقوله
إي ال features اللي يركز عليها في ال data عنده يقدر يطلع النتيجة الصح

Deep Learning: DL

* DL: involves neural net works 'nn' (involved nodes and statistical relationships between those nodes to model the way our minds work)

and it's called deep: cause we're doing multiple layers of nn

(Note: we don't Really understand how the system comes up with insights from nn)

ال DL عكس ال ML من حيث يحتاج أي توجيه من الإنسان لا features التي يملكها ال raw data وهو خلال ال layers يتاحه يكشف ويستخرج ال features والنتائج لودة بشكل تلقائي (Automatic Features Extraction)

DL is also a subset of ML ($DL \subset ML$) based on neural networks. it can ingest unstructured data and automatically determine features and hidden patterns without human intervention

* Neural Network (NN):

the backbone algorithm for deep learning, modeled after the human brain, a network is considered

"Deep" if it has more than > 3 layers

↳ (input, output, and hidden layers)

* the Black Box Concept.

يُعتبر الـ hidden layers في الـ NN واهم اراضي العمليات والآليات الضار بها النتيجة المعيرة مع نفقها أو نتيجتها لتفسير

* Weights.

Values assigned to inputs on a model to determine the level of importance or significance to the final output

الأوزان هي ارقام الموديل بيظهرها في input ختام ايجاد فيه تأثيره أقوى على النتيجة النهائية بمعنى:

لو هنري وزن جديد وعندي 3 عوامل بقدر فهم (العمر، الكمية، اللون)

1 [العمر فهم جدا أوليه وزن 9 من 10

2 [الكمية وزن 7 من 10 ، 3 [اللون فهمهم أوي أوليه 2 من 10

Weights = (9, 7, 2)

الموديل في البداية بيخمن الأرقام دي عشوائي ومع الشرب بيحرق الأرقام الصح اللي تطلع الضرار الصح

* Feed-Forward : the standard direction of data flow in NN, moving straight from input layer to output layer

اتجاه الحسابات في الـ NN يكون إتجاه واحد by default

input L → hidden L → output L.

والهدف منه حاب التوقع أو النتيجة النهائية بناءً على الأوزان الحالية


* Back-Propagation :-

↳ A training process that moves in opposite direction (from output to input) to calculate errors and adjust the weights of the neurons to improve accuracy

بعد مرحلة ال Feed-Forward الموديل طرح التوقع " output " ، فاضا بتقاربه بالحقيقة
مثلا الموديل طرح توقع خاطئ لصورة (قطة وبل كلب)

هنا يسمى دور ال back-propagation الاتجاه عكسي
 أنه ينقل قيمة الخطأ الذي ويرجع إليها لتضخيمه (input لا output)
 ويمر through layers بالعكس، وهو تراجع يمر على كل ال weights
 التي شاركت في القرار الخطأ ويغير قيمها أثناء المرة الجاهة لحاسوب
 نفس الصورة فيخلط نفس الخطأ

$$\{DL \subset ML \subset AI\}$$



ML: Supervised vs unsupervised vs Reinforcement

1] Supervised Learning

→ A. Classification → involves predicting a discrete class label

يُصنّف الأرقام التي يسجلها إلى موجب، سالب، Zero

→ B. Regression → involves predicting a continuous numerical value

البيانات التي يسجلها الأرقام والناتج وهو ما يحدد العلاقة أو القيمة التي تمت بينهم وتطبقها الأرقام الجديدة التي يسجلها ضمن الناتج "test" في يتوقع الناتج بناءً على البيانات التي اتعلمها مثال نرى توقع أسعار العقارات على ما حثنا

2] unsupervised learning:

→ (unlabeled data → clusters) = clustering (تجميع أو تصنيف)

يسجله مجموعة بيانات وأقلها تصنيف ليا كذا فيه في يسجله التي فيه بعض خصائصه سواء فيه وهكذا مع باقي البيانات ويحاول يسجل الترابط التي في البيانات غير مصنفة

3] Reinforcement learning:

↳ (reward & punishment)

نظام المكافأة والعقاب

الحويل هنا يكون أستاذ agent مشربيله دانا في الأول لكي يحطه بيئة معينة واسببة يحرب ولو في خطوه مع بيلاه مكافأ مثلاً (+5 Reward) ولو غلط بيضر (-5 Penalty) دة بيتخدم في ال Robots السيارات ذاتية القيادة

↳ Teaching an "Agent" how to interact with its environment, in order to meet its objectives

* Data Split : (train, test and validation sets)

دلو قتي عناه أدرب حويل ML و الداتا بقاين ذ لازم أقسمها الأول

⇒ how to split Data ?

1] Training "70%" → Model uses this data to study and learn patterns

2] Validation "10%" → used during the training phase to check how well the model is doing

3] ↳ if the model gets a bad score here, we change external settings "Hyperparameters" and train it again. and repeat the tuning until we get the best score.

3] test "20%" → the final step to evaluate the model, and contains the unseen data

↳ The Results shows how the model will perform in the Real world

Note: Sequential و Randomly إلى هاتين الطريقتين

* Random split: mix and split the data Randomly
↳ used for small normal models

* Sequential split: split the data with order of time
زي مثلاً لو عاوزة أتوقع أسعار الـ هب بكرة لازم أكون
عشمت البيانات بتسلسل زمني مرتب كأنه بكرة يفتح على النازدة وأخبار

if 'cat', 'dog', 'spotted'


if you notice there is no order for the classes

* **Variable Encodings** :
 ↳ as way we choose how to store data for use in machine learning ,

↳ A model needs all variables to be converted into numbers , but how we convert or store 'cat' or 'Dog' or 'zebra' as a number??

Before we answer this question , first we must know what types of variables we're dealing with :-

↓ ① * **Continuous Variables** : something you can measure.

ex weight (kg) 

as a consequence it's already a number so

No encoding need for it

Cause it's already what we want (a numerical value).

↓ ② * **Discrete or Categorical Variables** :

↳ this what we need encoding for

* this variables could be possible classes

: {'Cat', 'Dog', 'zebra'}

* if you notice there is no order for the classes therfor it's **Nominal** #

⇒ Nominal Categorical Variable encoding:

2. • use 'one-hot' encoding to designate the class

image	Animal	cat?	dog?	zebra?
1	Cat	①	0	0
2	dog	0	①	0
3	zebra	0	0	①
4	dog	0	①	0

2. • or use 'Dummy' encoding

image	Animal	cat	dog
1	Cat	1	0
2	dog	0	1
3	zebra	0	0
4	dog	0	1

الفرق بين one-hot وال dummy انه dummy بكل k-1 عمود في الفئات و لو في فئة ظهرت في كل الفئات يفترض اننا الأخير الذي حذفنا

③

Ordinal categorical variables:

possible classes: {'small', 'medium', 'large'}

means there is an order

فئات رتبة بين فيما ترتيب

2. • Use 'Ordinal Encoding'

بحول الفئات لأرقام ترتيبية

Small → 0

medium → 1

large → 2 and so on

بكذا نكون تحولنا numeric وحافظت مع الترتيب:

⑤ * Special case (Binary Categorical Variables):

→ Something that is one of 2 classes
{'cat', 'Dog'}

↳ • Use "Binary Encoding"

عني فسيه يا داما - or 1 أو 0

Cat → 1 , Dog → 0

Possible classes: {'small', 'medium', 'large'}

DATA Leakage in ML

✱ The problem happens when a ML model achieves high accuracy during training and testing, buttt! performs terribly in real world production. In other words the model cheated or had access to the test data during training.
↳ but how could that happen???

↳ causes:

1] Target Leakage

cause: including features in the training data that are generated after the target variable is realized or are direct proxies for the target

2] Train-Test Contamination "preprocessing leakage":

Cause: Performing data preprocessing like Normalization, Standardization, or missing value imputation on the entire data set before splitting it into Train and test sets

↳ here the info from the Test set like mean or STD leaks into the train set and so the model indirectly sees the test data during training.

* How to Handle data leakage (HAD)

① For Target leakage:

- perform careful EDA
- Drop Features that will not be available at the time of real-world prediction

② For Preprocessing leakage

→ Split First! Always

execute: `train_test_split` before doing any preprocessing

→ Apply `.fit()` or `.fit_transform()` strictly on the train data

→

→ Apply `.transform()` only on the test data

→ use Scikit-learn Pipelines:

(`sklearn.pipeline.Pipeline`) → it automates the workflow and strictly isolates data folds, making data leakage practically impossible during ~~validation~~ validation